

Cyberbullying Tweets

Sistemi Intelligenti 2025/26,

Daniele Spinelli e Simone Albano

1. Introduzione

Questo progetto affronta un problema di **classificazione multiclasse**, una tipologia di apprendimento supervisionato, applicato al dominio del processo del linguaggio naturale (NLP). L'obiettivo della pipeline di Machine Learning è quello di riconoscere e categorizzare tweet che presentano atti di **cyberbullismo**. Il dataset utilizzato, selezionato da Kaggle, è "[Cyberbullying Tweets](#)". L'insieme dei dati è composto da decine di migliaia di tweet originariamente forniti in una condizione di sostanziale **bilanciamento**, suddivisi in **6 classi target**: *age, ethnicity, gender, religion, other_cyberbullying, not_cyberbullying*.


2. Analisi esplorativa

Per comprendere al meglio la **distribuzione** e l'eventuale presenza di “**rumore**” nei testi, sono state prodotte delle **WordCloud** per ciascuna classe. Questa indagine ha evidenziato un'elevata **eterogeneità** e **sovrapposizione** tra le categorie **other** e **not cyberbullying**. Inoltre ha rilevato la presenza di termini **privi di senso** come frammenti di URL (“http”, “https”) o **acronimi** del dominio (“rt” per retweet).

Le Parole più Frequenti per ogni Categoria (Notare la confusione in 'OTHER')



Per indagare meglio su queste classi ambigue, è stato scelto di applicare la **Non-negative Matrix Factorization (NMF)**, una potente tecnica di apprendimento non supervisionato e di riduzione della dimensionalità che permette di scoprire strutture nei dati. E' stata configurata per estrarre 4 topic latenti solo per la classe *other_cyberbullying*. L'ispezione ha confermato concretamente le supposizioni ed evidenze riscontrate durante la visualizzazione delle WordCloud.



Infine, dopo un'analisi manuale del dataset, è apparsa chiara una problematica **intrinseca** di esso. Diversi tweet risultano **etichettati** in modo errato dai creatori del dataset.

es.

- I AM SO FUCKING EXCITED ARE YOU EXCITED, other_cyberbullying
- P, other_cyberbullying
- Why would I choose to go there, other_cyberbullying

3. Pre-processing e Feature Engineering

La fase di pre-processing è stata strutturata in modo **sequenziale** per **mitigare** le criticità emerse durante le fasi precedenti e favorire l'**estrazione** di informazioni **rilevanti** e “pulite”.

Come prima metodologia è stata scelta la suddivisione del dataset in **70 % Training Set** e **30% Test Set**, in modalità stratificata (garantendo il mantenimento delle stesse proporzioni delle classi) e prevenendo il *data leakage*.

Successivamente, si è provveduto a trasformare i testi in vettori numerici tramite la tecnica **TF-IDF** (term frequency–inverse document frequency) . Durante questo step, è stata effettuata una *Feature Selection* manuale, aggiungendo al vocabolario standard delle *stopword* inglesi, i termini rumorosi individuati in fase esplorativa (http, rt, ecc). L'estrazione è stata configurata per catturare sia gli unigrammi che i bigrammi (*ngram_range=(1,2)*), per non disperdere il contesto semantico (es. insulti composti) e inserendo il limite di feature discriminanti a 10.000 (*max_features=100000*), ottimizzando le risorse di calcolo. Inoltre sono stati rimossi i termini presenti in meno di due documenti e quelli in più del 95% (*min_df=2* e *max_df=0.95*).

Infine, per limare l'ambiguità residua evidenziata tra le classi, è stato applicato esclusivamente al Training Set l'algoritmo **SMOTETomek**. Nonostante il dataset originale fosse numericamente bilanciato, tale metodo è stato scelto per la sua componente di **undersampling** basata sui **Tomek Links**. Questa tecnica ha permesso di scovare e rimuovere le istanze ambigue posizionate ai **confini** decisionali tra le classi (specialmente per other e not cyberbullying).

```
--- APPLICAZIONE SMOTETOMEK (RIMOZIONE TWEET AMBIGUI) ---  
Campioni PRIMA di SMOTETomek: 33384  
Campioni DOPO i Tomek Links: 32624  
Nota: La differenza numerica rappresenta i campioni 'rumorosi' o sovrapposti eliminati ai confini delle classi (760).
```


4. Algoritmi di Classificazione e Scelta dei parametri

Per risolvere il task, sono stati implementati e confrontati diversi modelli di classificazione (hard), partendo da metodologie basilari fino a raggiungere modelli *ensemble*, evidenziando la ricerca di algoritmi sempre più adatti all'obiettivo scelto.

1. K-NN

Il primo algoritmo testato è stato il K-Nearest Neighbors, un classificatore che si basa sulle caratteristiche delle componenti vicine a quello considerato. E' stato impostato il numero di vicini **k = 5** e pesato i contributi sulla base della distanza (*weights='distance'*). Durante questa fase si è proceduto alla comparazione di due



diverse metriche di distanza, **distanza Euclidea** e la **similarità del Coseno**. Essendo i testi vettorializzati, la similarità del Coseno è intrinsecamente più adatta a catturare la vicinanza semantica (angolo) tra i vettori testuali.





2. Alberi di Decisione e Profondità ottimale

Successivamente è stato addestrato un **Albero di Decisione**, modello che crea una struttura gerarchica partizionando ricorsivamente i dati. L'algoritmo ha utilizzato l'**indice di Gini** come metrica per valutare gli attributi scelti per lo split. Per trovare la **profondità massima ottimale** per il modello, l'albero è stato addestrato iterativamente con profondità **diverse** (1, 2, 3, 5, 10, 15, None). Impostando il parametro della **max_depth** uguale a **None**, l'algoritmo ha fatto crescere l'albero quanto bastava per classificare chirurgicamente i dati di addestramento, toccando il **96.7%** di **accuracy** sul **Training Set**, ma crollando all'**80.3%** sul **Test Set**. Questa differenza rappresenta in modo evidente il fenomeno dell'**overfitting**, il modello ha imparato a memoria i dati di addestramento, fallendo così nella fase di testing, con dati mai visti.

```
--- ADDESTRAMENTO ALBERO DI DECISIONE CON DEPTH 10---
max_depth=1 -> train=0.3212, test=0.3206
max_depth=2 -> train=0.4236, test=0.4231
max_depth=3 -> train=0.5055, test=0.5022
max_depth=5 -> train=0.5866, test=0.5836
max_depth=10 -> train=0.6947, test=0.6873
max_depth=15 -> train=0.7672, test=0.7560
max_depth=None -> train=0.9665, test=0.8015
--- ADDESTRAMENTO ALBERO DI DECISIONE CON DEPTH NONE---
--- ADDESTRAMENTO RANDOM FOREST (5 alberi)---
--- ADDESTRAMENTO RANDOM FOREST (200 alberi)---
```



Per superare i limiti strutturali e la forte sensibilità al rumore del singolo Albero di decisione, si è passati ad un metodo **ensemble**, la **Random Forest**. Si addestrano simultaneamente molteplici alberi su un sottoinsieme di dati *randomici* e, aggregandone le predizioni, la foresta abbate la varianza limitando l'overfitting. Si è partiti da una configurazione base di **5 alberi** ($n_estimators=5$), per poi portare tale parametro a **200** ($n_estimators=200$). L'innalzamento del numero di stimatori ha fornito un modello più stabile e nettamente più accurato, specialmente nelle classi ambigue



5. Valutazione e Commento critico ai risultati





Per stimare e confrontare la **capacità predittiva** sul Test Set dei modelli addestrati, sono stati estrapolati dei **report** completi basati sulle fondamentali metriche di classificazione: **Accuracy, Precision, Recall e F1-Score**. Per avere un quadro visivo immediato i risultati statistici globali sono stati accompagnati dalla visualizzazione grafica delle **Matrici di Confusione** e dai **diagrammi a barre** dei report. Questo strumento permette di osservare sulla diagonale principale i True Positive e True Negative e fuori da essa l'incidenza di False Positive e False Negative.

L'analisi dei diagrammi dimostra che la pipeline composta da pre-processing, bilanciamento e rimozione dei campioni ambigui del dataset (SMOTETomek e Tomek links) e l'impiego della Random Forest (200 alberi) risulta nettamente vincitrice.

Confrontando le Matrici di Confusione e il grafico di Wordcloud, notiamo che le performance sono eccellenti nelle classi portatrici di un vocabolario specifico e discriminante (come age, ethnicity e religion) mentre sono più imprecise nelle classi con etichette ambigue (not e other_cyberbullying).

Alla luce dell'analisi esplorativa dei dati condotta inizialmente, possiamo concludere criticamente che questa confusione residua non rappresenta un fallimento o un limite algoritmico, bensì un limite intrinseco della base dati stessa, che presenta una profonda ambiguità semantica e inclusioni di *label noise* originario impossibili da separare con assoluta certezza matematica.

Performance dei Classificatori



--- METRICHE COMPLESSIVE PER MODELLO ---

k-NN Euclidean

Accuracy:	0.3187
Precision:	0.6512
Recall:	0.3196
F1-Score:	0.3318

k-NN Coseno

Accuracy:	0.6845
Precision:	0.7161
Recall:	0.6838
F1-Score:	0.6962

Decision Tree (Depth=10)

Accuracy:	0.6873
Precision:	0.8210
Recall:	0.6878
F1-Score:	0.6726

Decision Tree (Depth=None)

Accuracy:	0.8015
Precision:	0.8035
Recall:	0.8005
F1-Score:	0.8019

Random Forest (5 Alberi)

Accuracy:	0.8129
Precision:	0.8123
Recall:	0.8120
F1-Score:	0.8119

Random Forest (200 Alberi)

Accuracy:	0.8320
Precision:	0.8332
Recall:	0.8312
F1-Score:	0.8311